---

1. 프로젝트 제목

모바일·간편결제 확산 시대의 카드 고객 유지 전략

신용카드 이용 행동 기반 이탈 위험 세그먼트 분석과 개인화 유지 전략 제안

---

2. 프로젝트 배경 및 문제의식

최근 결제 시장은 빠르게 변화하고 있다. 과거에는 소비자가 실물 신용카드를 직접 사용해 결제하는 경우가 많았지만, 최근에는 모바일 지갑, 간편결제, 앱카드, 삼성페이·네이버페이·카카오페이 등 다양한 비실물 결제 방식이 확산되고 있다.

이 변화는 단순히 결제 수단이 플라스틱 카드에서 스마트폰으로 바뀌는 문제만은 아니다. 카드가 물리적 지갑 안에 존재하던 시기에는 특정 카드가 자연스럽게 주 사용 카드가 되는 경우가 많았지만, 모바일 결제 환경에서는 여러 카드와 결제수단이 한 플랫폼 안에 함께 등록된다. 이에 따라 소비자는 특정 카드사에 장기적으로 충성하기보다, 혜택, 캐시백, 포인트, 제휴처, 편의성에 따라 결제수단을 더 유동적으로 선택할 수 있다.

즉, 카드사 입장에서는 단순히 “카드를 발급한 고객 수”보다 다음 질문이 더 중요해지고 있다.

> 고객이 실제로 우리 카드를 계속 사용하고 있는가**?**
> 어떤 고객의 사용이 줄어들고 있는가**?**
> 어떤 고객이 이탈 위험을 보이고 있는가**?**
> 고객군별로 어떤 유지·재활성화 전략이 필요한가**?**

따라서 본 프로젝트는 신용카드 고객의 이용 행동 데이터를 기반으로 고객을 여러 세그먼트로 나누고, 각 세그먼트가 이탈 위험과 어떤 관계를 가지는지 분석하고자 한다. 단순히 이탈 여부를 예측하는 classification 프로젝트가 아니라, 고객의 활동성, 거래 감소, 관계 강도, 비활성 신호, 접촉 빈도 등을 바탕으로 마케팅 전략이 달라져야 하는 고객군을 발견하는 것이 핵심이다.

---

3. 핵심 문제 정의

기존의 일반적인 접근은 다음과 같다.

> 고객 데이터 → 이탈 여부 예측 → 중요한 변수 확인

하지만 이 방식은 카드사 입장에서 충분하지 않을 수 있다. 이탈 확률이 비슷한 고객이라도 이탈 원인이나 필요한 대응 전략은 다를 수 있기 때문이다.

예를 들어 같은 이탈 위험 고객이라도 다음과 같이 서로 다른 유형이 존재할 수 있다.

고객 유형	주요 특징	필요한 전략
거래 감소 고객	최근 거래 횟수·금액 감소	혜택 기반 재활성화
비활성 고객	최근 12개월 중 사용하지 않은 기간 증가	앱 푸시, 재사용 쿠폰
접촉 과다 고객	고객센터 접촉 횟수 증가	불만 해결형 상담
관계 약한 고객	보유 상품 수 낮고 사용량 적음	저비용 디지털 캠페인
고활성 충성 고객	거래 많고 비활성 낮음	장기 혜택, VIP 유지 전략

따라서 본 프로젝트는 단순히 “누가 이탈할 것인가?”가 아니라 다음 질문에 집중한다.

> 카드 고객은 어떤 이용 행동 패턴에 따라 세그먼트화되며, 각 세그먼트에는 어떤 유지 전략이 필요한가?

---

4. 프로젝트 목표

본 프로젝트의 목표는 크게 네 가지이다.

첫째, 신용카드 고객의 이용 행동과 관계 강도에 따라 고객 세그먼트를 도출한다.

둘째, 각 세그먼트의 이탈률, 거래 행동, 비활성 수준, 접촉 빈도, 관계 상품 수를 비교하여 세그먼트의 의미를 해석한다.

셋째, 새로운 고객이 어느 세그먼트에 속하는지 예측하는 classification 모델을 구축하고, feature importance를 통해 세그먼트 구분 근거를 설명한다.

넷째, 각 세그먼트별로 카드사 관점의 유지, 재활성화, 혜택 제공, 리스크 관리 전략을 제안한다.

---

5. 사용 데이터셋

Credit Card Customers / BankChurners Dataset

본 프로젝트에서는 공개 신용카드 고객 이탈 데이터셋인 **Credit Card Customers**, 흔히 **BankChurners Dataset**으로 불리는 데이터를 사용한다.

이 데이터셋은 신용카드 고객의 인구통계 정보, 카드 이용 행동, 은행과의 관계 정보, 최근 거래 변화, 비활성 기간, 접촉 횟수, 이탈 여부 등을 포함한다.

주요 변수는 다음과 같다.

구분	변수 예시	설명
고객 기본 정보	`Customer_Age`, `Gender`, `Education_Level`, `Marital_Status`, `Income_Category`	연령, 성별, 교육 수준, 결혼 여부, 소득 구간
카드 관계 정보	`Months_on_book`, `Total_Relationship_Count`, `Card_Category`	카드 이용 기간, 관계 상품 수, 카드 등급
비활성 신호	`Months_Inactive_12_mon`	최근 12개월 중 비활성 개월 수
접촉 신호	`Contacts_Count_12_mon`	최근 12개월 고객 접촉 횟수
신용 한도 및 이용	`Credit_Limit`, `Total_Revolving_Bal`, `Avg_Open_To_Buy`, `Avg_Utilization_Ratio`	신용 한도, 회전 잔액, 가용 한도, 한도 사용률
거래 행동	`Total_Trans_Amt`, `Total_Trans_Ct`	총 거래 금액, 총 거래 횟수
거래 변화	`Total_Amt_Chng_Q4_Q1`, `Total_Ct_Chng_Q4_Q1`	최근 거래 금액 변화율, 거래 횟수 변화율
결과 변수	`Attrition_Flag`	기존 고객 / 이탈 고객

---

6. 데이터 사용상의 한계와 해석 범위

이 데이터셋은 신용카드 고객의 이용 행동과 이탈 여부를 포함하지만, 실물카드 결제와 모바일·비실물 결제를 직접 구분하는 변수는 포함하지 않는다.

따라서 본 프로젝트는 다음과 같이 해석 범위를 제한한다.

부적절한 해석:

> 모바일 결제 확산 때문에 이 고객들이 이탈했다.

적절한 해석:

> 모바일·간편결제 확산으로 카드 고객의 충성도가 약화될 수 있는 시장 환경에서, 신용카드 고객의 거래 감소, 비활성화, 관계 약화 신호를 기반으로 이탈 위험 세그먼트를 분석한다.

즉, 한국의 실물카드 사용 감소와 모바일 결제 확산은 본 프로젝트의 문제의식과 배경이며, 실제 분석 대상은 공개 데이터셋에서 관측 가능한 신용카드 고객의 이용 행동과 이탈 위험 구조이다.

---

7. Research Questions

RQ1. 카드 고객은 이용 행동과 관계 강도에 따라 어떤 세그먼트로 나뉘는가**?**

고객의 거래 횟수, 거래 금액, 비활성 기간, 거래 변화율, 관계 상품 수, 고객 접촉 횟수, 한도 사용률 등을 기반으로 clustering을 수행한다.

이때 `Attrition_Flag`는 clustering input에 사용하지 않는다. 고객의 행동 feature만으로 세그먼트를 만든 뒤, 각 세그먼트의 이탈률을 사후적으로 비교한다.

예상 가능한 세그먼트는 다음과 같다.

예상 세그먼트	주요 특징	해석
고활성 충성 고객군	거래 횟수·금액 높고 비활성 낮음	핵심 유지 고객
거래 감소 위험군	최근 거래 횟수·금액 감소	혜택 또는 대체 결제수단으로 이동 가능성
비활성 이탈 위험군	비활성 개월 수 높음	카드 사용 습관 약화
접촉 과다 불만 가능군	고객 접촉 횟수 많음	불만 또는 문제 해결 실패 가능성
관계 약한 저활성 고객군	관계 상품 수 낮고 거래 적음	낮은 충성도, 혜택 중심 유동 고객
한도 활용 높은 고객군	한도 사용률 높음	수익성과 리스크를 함께 고려해야 하는 고객

RQ2. 각 세그먼트는 실제 이탈률에서 어떤 차이를 보이는가**?**

고객 행동을 기준으로 도출한 클러스터별로 `Attrition_Flag` 비율을 비교한다.

이 분석의 목적은 단순히 이탈 고객을 맞히는 것이 아니라, 다음을 확인하는 것이다.

> 고객 행동 기반으로 나눈 세그먼트가 실제 이탈 위험에서도 의미 있는 차이를 보이는가?

예를 들어 거래 감소 위험군이나 비활성 이탈 위험군에서 실제 이탈률이 높게 나타난다면, 해당 세그먼트는 카드사 입장에서 우선적인 유지 전략 대상이 될 수 있다.

RQ3. 고객 충성도 약화는 어떤 행동 신호로 나타나는가**?**

이탈 위험이 높은 세그먼트가 어떤 행동적 특징을 보이는지 분석한다.

주요 후보 신호는 다음과 같다.

- 거래 횟수 감소
- 거래 금액 감소
- 최근 12개월 비활성 개월 수 증가
- 고객 접촉 횟수 증가
- 관계 상품 수 감소 또는 낮음
- 한도 사용률 변화
- 카드 이용 기간 대비 낮은 거래량

이 RQ는 최근 문제의식과 직접 연결된다.

> 카드가 발급되어 있더라도 실제 사용이 줄어들고 있다면, 고객과 카드사의 관계는 약화되고 있을 수 있다.

RQ4. 새로운 고객이 어느 이탈 위험 세그먼트에 속하는지 예측할 수 있는가**?**

Clustering 결과를 pseudo-label로 사용해 classification 모델을 학습한다.

사용 가능한 모델은 다음과 같다.

- Logistic Regression
- Decision Tree
- Random Forest
- XGBoost / LightGBM

- SVM

이 classification의 목적은 이탈 여부 자체를 예측하는 것이 아니다.

> 새로운 고객을 유지 전략이 다른 세그먼트에 배정하는 모델을 만드는 것이 목적이다.

평가 지표는 다음을 사용할 수 있다.

- Accuracy
- Macro F1-score
- Confusion Matrix
- 클러스터별 precision/recall

RQ5. 세그먼트별로 어떤 유지·재활성화 전략이 적절한가**?**

각 세그먼트의 특성과 이탈률을 바탕으로 카드사 관점의 마케팅 전략을 제안한다.

세그먼트	데이터상 특징	전략 제안
고활성 충성 고객군	거래 많고 이탈률 낮음	장기 이용 보상, VIP 혜택, 주 사용 카드 유지 전략
거래 감소 위험군	최근 거래 횟수·금액 감소	맞춤형 캐시백, 월별 미션, 카테고리별 혜택 강화
비활성 이탈 위험군	비활성 개월 수 높음	앱 푸시, 재사용 쿠폰, 간편결제 등록 유도
접촉 과다 불만 가능군	고객 접촉 횟수 높음	불만 해결형 상담, 서비스 품질 개선
관계 약한 저활성 고객군	관계 상품 수 낮고 거래 적음	저비용 디지털 캠페인, 첫 사용/재사용 유도
한도 활용 높은 고객군	한도 사용률 높음	리스크 관리, 분할상환 안내, 맞춤형 금융지원

---

8. 분석 방법론

Step 1. EDA

먼저 전체 고객 구조와 이탈률을 파악한다.

분석 항목은 다음과 같다.

- 전체 이탈률
- 이탈/비이탈 고객의 거래 횟수 차이
- 이탈/비이탈 고객의 거래 금액 차이
- 비활성 개월 수와 이탈률 관계
- 고객 접촉 횟수와 이탈률 관계
- 관계 상품 수와 이탈률 관계
- 거래 횟수 변화율과 이탈률 관계
- 거래 금액 변화율과 이탈률 관계
- 한도 사용률과 이탈률 관계
- 연령, 소득, 성별, 카드 등급별 이탈률 차이

EDA 단계의 핵심 메시지는 다음이다.

> 카드 고객 이탈은 단일 변수로 설명되기보다, 거래 감소, 비활성화, 관계 약화, 접촉 증가 등 여러 행동 신호가 결합되어 나타날 수 있다.

Step 2. Feature Engineering

Raw data를 그대로 clustering에 넣기보다, 카드 고객의 행동을 설명하는 해석 가능한 축을 설계한다.

1. Activity: 카드 이용 활성도

고객이 카드를 얼마나 활발히 사용하는지 나타내는 축이다.

관련 변수:

- `Total_Trans_Ct`
- `Total_Trans_Amt`
- `Months_Inactive_12_mon`

해석:

> 거래 횟수와 금액이 높고 비활성 기간이 짧을수록 활성도가 높은 고객으로 볼 수 있다.

---

2. Decline Signal: 사용 감소 신호

최근 거래가 줄어들고 있는지 나타내는 축이다.

관련 변수:

- `Total_Ct_Chng_Q4_Q1`
- `Total_Amt_Chng_Q4_Q1`

해석:

> 최근 거래 횟수나 금액이 감소하는 고객은 혜택 변화, 대체 결제수단 이동, 카드 사용 습관 약화 가능성이 있다.

---

3. Relationship Strength: 관계 강도

고객과 카드사 간 관계가 얼마나 깊은지 나타내는 축이다.

관련 변수:

- `Months_on_book`
- `Total_Relationship_Count`

해석:

> 카드 이용 기간이 길고 관계 상품 수가 많을수록 관계 강도가 높다고 볼 수 있다.

---

4. Contact Burden: 접촉 부담 또는 불만 가능성

고객이 카드사와 얼마나 자주 접촉했는지 나타내는 축이다.

관련 변수:

- `Contacts_Count_12_mon`

해석:

> 접촉 횟수가 많다는 것은 단순 문의일 수도 있지만, 불만이나 문제 해결 과정의 신호일 가능성도 있다.

---

5. Credit Utilization: 한도 활용도

고객이 신용한도를 얼마나 사용하는지 나타내는 축이다.

관련 변수:

- `Credit_Limit`
- `Total_Revolving_Bal`
- `Avg_Open_To_Buy`
- `Avg_Utilization_Ratio`

해석:

> 한도 활용률은 고객의 카드 의존도, 수익성, 리스크를 함께 보여줄 수 있다.

Step 3. 전처리

금융 데이터는 scale 차이와 skew가 크기 때문에 raw data를 그대로 사용하지 않는다.

전처리 방식:

- 결측치 확인
- 불필요한 ID 제거
- 범주형 변수 encoding
- 수치형 변수 scaling
- 거래 금액, 신용한도 등 skewed feature에 log transform 적용
- 이상치 winsorization 또는 clipping
- StandardScaler와 RobustScaler 비교

특히 clustering input과 profiling feature를 분리한다.

구분	사용 변수
Clustering input	거래 행동, 비활성, 변화율, 관계 강도, 한도 활용도
Profiling feature	인구통계, 소득, 카드 등급, 이탈 여부

이렇게 하면 고객군이 단순히 성별이나 소득 같은 인구통계 기준으로 나뉘는 것을 방지하고, 실제 카드 이용 행동 중심으로 세그먼트를 도출할 수 있다.

Step 4. Clustering

고객 행동 feature를 기반으로 clustering을 수행한다.

사용 알고리즘:

- K-Means
- Gaussian Mixture Model
- Agglomerative Clustering

클러스터 수는 4~6개를 중심으로 비교한다.

클러스터 수 선택 기준:

- Elbow method
- Silhouette score
- Davies-Bouldin index
- Calinski-Harabasz score
- 클러스터 크기 균형
- 세그먼트 해석 가능성
- 세그먼트별 이탈률 차이
- 마케팅 전략 연결 가능성

중요한 점은 2D 시각화에서 군집이 예쁘게 나뉘는지보다, 각 세그먼트가 행동 profile과 이탈률에서 의미 있는 차이를 보이는지 확인하는 것이다.

Step 5. Segment Profiling

각 cluster의 특징을 해석한다.

주요 분석 항목:

- 평균 거래 횟수
- 평균 거래 금액
- 거래 횟수 변화율
- 거래 금액 변화율
- 비활성 개월 수
- 고객 접촉 횟수
- 관계 상품 수
- 카드 이용 기간
- 한도 사용률
- 카드 등급
- 소득 구간
- 이탈률

예상 segment profiling 예시는 다음과 같다.

Segment	주요 특징	이탈률	전략적 해석
S1. Active Loyalists	거래 많고 비활성 낮음	낮음	주 사용 카드 고객, 장기 유지 대상
S2. Declining Users	거래 변화율 감소	중~높음	혜택 기반 재활성화 필요

S3. Dormant Customers	비활성 개월 수 높음	높음	카드 사용 습관 약화
S4. High-contact Risk	접촉 횟수 많음	높음	불만 또는 서비스 문제 가능성
S5. Thin Relationship Users	관계 상품 수 낮고 거래 적음	중	충성도 낮은 유동 고객
S6. Credit-dependent Users	한도 활용률 높음	중	수익성과 리스크를 함께 관리해야 함

Step 6. Classification

Clustering 결과로 얻은 segment label을 target으로 하여 classification 모델을 학습한다.

이 단계의 목적은 다음이다.

> 새로운 고객의 최근 이용 행동이 주어졌을 때, 어떤 유지 전략 세그먼트에 속하는지 예측한다.

사용 모델:

- Logistic Regression
- Decision Tree
- Random Forest
- XGBoost / LightGBM

평가 지표:

- Accuracy
- Macro F1-score
- Confusion Matrix
- Segment별 precision/recall

주의할 점:

> 이 classification은 이탈 여부 예측이 아니라, 고객을 해석 가능한 세그먼트에 배정하기 위한 보조 분석이다.

Step 7. Feature Importance

두 종류의 feature importance를 비교한다.

A. 세그먼트 분류 feature importance

질문:

> 고객을 서로 다른 세그먼트로 나누는 핵심 기준은 무엇인가?

예상 중요 feature:

- 거래 횟수
- 거래 금액
- 비활성 개월 수
- 거래 변화율
- 관계 상품 수
- 한도 사용률

B. 이탈 예측 feature importance

보조적으로 이탈 여부 예측 모델을 만들고, 실제 이탈을 설명하는 feature도 확인할 수 있다.

질문:

> 세그먼트를 구분하는 feature와 실제 이탈을 설명하는 feature는 같은가?

이 비교는 프로젝트의 분석 깊이를 높일 수 있다.

예를 들어 거래 규모는 세그먼트 구분에는 중요하지만, 실제 이탈 위험은 거래 변화율이나 비활성 개월 수가 더 잘 설명할 수 있다.

Step 8. High-risk Signal Overlap 분석

극단적인 고객만 clustering input으로 넣지는 않되, 보조 분석으로 high-risk signal을 정의한다.

예시 high-risk 조건:

- `Months_Inactive_12_mon` 상위 20%
- `Total_Ct_Chng_Q4_Q1` 하위 20%
- `Total_Amt_Chng_Q4_Q1` 하위 20%
- `Contacts_Count_12_mon` 상위 20%

이후 이 high-risk signal 고객들이 어떤 세그먼트에 많이 포함되는지 확인한다.

분석 질문:

> 우리가 도출한 이탈 위험 세그먼트는 실제 고위험 행동 신호를 가진 고객들을 잘 포착하는가?

이 분석은 clustering 결과의 타당성을 보강해준다.

---

9. 추천 시각화

2D scatter plot에서 cluster가 예쁘게 분리되지 않을 수 있으므로, 다음 시각화를 중심으로 사용한다.

1. Cluster Profile Heatmap

세그먼트별 주요 feature의 표준화 평균값을 heatmap으로 표현한다.

목적:

> 각 세그먼트가 어떤 행동적 특징을 가지는지 직관적으로 보여준다.

---

2. Segment별 이탈률 Bar Chart

각 세그먼트의 `Attrition_Flag` 비율을 비교한다.

목적:

> 행동 기반 세그먼트가 실제 이탈 위험과 연결되는지 확인한다.

---

3. Segment Size vs Attrition Rate Bubble Chart

- x축: segment size
- y축: attrition rate
- bubble size: 평균 거래 금액 또는 총 거래 금액

목적:

> 이탈률이 높지만 규모가 작은 세그먼트와, 이탈률은 중간이지만 고객 수가 많은 세그먼트를 구분한다.

---

4. Radar Chart

세그먼트별로 다음 5개 축을 비교한다.

- Activity
- Decline Risk
- Relationship Strength
- Contact Burden
- Credit Utilization

목적:

> 세그먼트의 성격을 발표에서 쉽게 설명한다.

---

5. PCA/UMAP 시각화

보조적으로 2D 투영을 사용한다.

단, 해석은 조심해야 한다.

> PCA/UMAP 시각화는 고차원 고객 행동 feature를 2차원으로 투영한 참고 자료이며, 최종 해석은 cluster profile과 이탈률 차이를 중심으로 수행한다.

---

10. 기대 결과 및 인사이트

이 프로젝트에서 기대할 수 있는 인사이트는 다음과 같다.

1. 카드 고객은 단순히 이탈/비이탈로 나뉘지 않는다

같은 이탈 위험 고객이라도 다음과 같이 서로 다른 유형이 존재할 수 있다.

- 사용량이 줄어드는 고객
- 이미 비활성화된 고객
- 고객센터 접촉이 많은 고객
- 관계 상품 수가 낮은 고객
- 한도 활용률이 높은 고객

따라서 카드사는 모든 이탈 위험 고객에게 같은 혜택을 제공하기보다, 세그먼트별로 다른 전략을 적용해야 한다.

---

2. 발급 고객 수보다 실제 사용 지속성이 중요하다

모바일·간편결제 시대에는 고객이 카드를 발급받았더라도 실제로 계속 사용하는지는 별개의 문제이다.

따라서 카드사 입장에서는 다음 지표가 중요하다.

- 거래 횟수
- 거래 금액
- 최근 거래 변화율
- 비활성 기간
- 관계 상품 수
- 고객 접촉 횟수

---

3. 이탈 위험은 단일 지표가 아니라 행동 신호의 조합으로 나타난다

예를 들어 거래 횟수가 낮다고 해서 모두 이탈 위험 고객은 아닐 수 있다.
거래 횟수는 낮지만 관계 상품 수가 많거나 한도 활용률이 높은 고객은 다른 전략이 필요할 수 있다.

반대로 거래 규모가 크더라도 최근 거래 변화율이 급격히 감소했다면 이탈 위험 신호일 수 있다.

---

4. 세그먼트별 전략은 달라야 한다

예상 전략은 다음과 같다.

세그먼트	전략
고활성 충성 고객	장기 이용 보상, 프리미엄 혜택
거래 감소 위험 고객	카테고리 맞춤 캐시백, 혜택 리마인드
비활성 고객	재사용 쿠폰, 앱 푸시, 간편결제 등록 유도
접촉 과다 고객	불만 해결형 상담, 서비스 품질 개선
저관계 고객	저비용 디지털 캠페인
한도 활용 고객	리스크 관리와 유지 전략 병행

---

11. 프로젝트의 한계

한계 **1.** 모바일**/**비실물 결제 여부를 직접 관측할 수 없다

이 데이터셋에는 실물카드 결제와 모바일 결제를 구분하는 변수가 없다.
따라서 본 프로젝트는 모바일 결제 전환 자체를 직접 분석하지 않는다.

대신 모바일·간편결제 확산으로 카드사 충성도가 약화되는 시장 환경에서, 고객의 거래 감소와 비활성 신호를 기반으로 이탈 위험 세그먼트를 분석한다.

한계 **2.** 한국 카드사 고객 데이터가 아니다

데이터는 해외 공개 데이터셋이며, 한국 카드사 고객의 실제 데이터를 직접 반영하지 않는다.
따라서 한국 결제 시장에 직접 일반화할 수는 없다.

다만 금융 고객 데이터는 개인정보와 거래 민감성 때문에 공개되기 어렵기 때문에, 본 프로젝트에서는 공개 가능한 신용카드 고객 이탈 데이터를 활용해 분석 프레임워크를 제안한다.

한계 **3.** 이탈 원인을 직접 증명할 수 없다

이탈 여부와 행동 feature 간 관계를 분석할 수는 있지만, 고객이 왜 이탈했는지 직접 알 수는 없다.

예를 들어 거래 감소가 혜택 부족 때문인지, 다른 카드 사용 때문인지, 소득 변화 때문인지, 단순 소비 감소 때문인지는 데이터만으로 구분하기 어렵다.

따라서 결과는 인과적 결론이 아니라 이탈 위험 신호와 유지 전략 가설로 해석한다.

한계 **4. Clustering** 결과는 자연적으로 존재하는 고객군이 아닐 수 있다

Clustering은 알고리즘과 feature 선택에 따라 달라질 수 있다.
따라서 본 프로젝트에서는 여러 clustering 알고리즘과 클러스터 수를 비교하고, profile 해석 가능성, 이탈률 차이, 전략 연결 가능성을 함께 검토한다.

---

12. 최종 요약

본 프로젝트는 최근 실물카드 사용 감소와 모바일·간편결제 확산이라는 결제 시장 변화를 배경으로 한다. 다만 실제 분석은 모바일 결제 여부를 직접 분석하는 것이 아니라, 공개 신용카드 고객 데이터를 활용해 카드 고객의 이용 행동과 이탈 위험 세그먼트를 분석한다.

핵심은 단순 이탈 예측이 아니라 다음 질문이다.

> 카드 고객은 어떤 행동 패턴에 따라 관계가 약화되며, 카드사는 각 고객군에게 어떤 유지 전략을 적용해야 하는가?

이 주제는 금융권 마케팅 세그먼트 분석이라는 큰 틀을 유지하면서도, 최근 결제 시장의 변화와 고객 충성도 약화라는 현실적인 문제의식을 반영할 수 있다.